Métodos de Estimación

Hugo Erich Domenack Quiñones
UNI

Mayo 2022

Algunos Conceptos Previos

- **LÍMITE PROBABILÍSTICO (PLIM):** Propiedad en grandes muestras (o asintótica) que indica que una (o varias) variable aleatoria X_n converge en probabilidad a una variable aleatoria X (o constante) siempre que se cumpla:

$$\lim_{n\to\infty} P[|X_n - X| \leq \varepsilon] = 1$$

Donde ε es un valor muy cercano a cero. También puede representarse de la siguiente manera:

$$\operatorname*{plim}_{n\to\infty} X_n = X$$

- **MATRIZ DE INFORMACIÓN (*I(ϑ)*):** Es el negativo del valor esperado de la matriz de segundas derivadas (Hessiana) de la función de log – verosimilitud:

$$I(\theta) = -E\left[\frac{\partial^2 l(\theta)}{\partial\theta\,\partial\theta'}\right]$$

- **COTA DE CRAMER – RAO:** Corresponde a la inversa de la "Matriz de Información".

$$V\left[\widehat{\theta_{MV}}\right] = [I(\theta)]^{-1}$$

Y es la mínima varianza que puede alcanzar un estimador insesgado.

Método de Mínimos Cuadrados Ordinarios (MCO)

Es el método de estimación más conocido y utilizado. Su aplicación más conocida es en los modelos de regresión lineal, que tienen la siguiente estructura:

$$Y_i = X_i\beta + e_i$$

Consiste en estimar los parámetros a partir de la minimización de la suma de cuadrados de los errores (función de pérdida):

$$min_\beta SSR = e'e = (Y - X\beta)'(Y - X\beta)$$

Dando como resultado el siguiente estimador:

$$\widehat{\beta_{MCO}} = (X'X)^{-1}X'Y$$

Propiedades del Estimador MCO

- Insesgadez: En promedio, se espera que el estimador iguale al parámetro teórico.

$$E\left[\widehat{\beta_{MCO}}\right] = \beta$$

- Consistencia: En muestras grandes, el estimador MCO converge al parámetro teórico, con varianza nula.

$$\lim_{n\to\infty} \widehat{\beta_{MCO}} = \beta$$

$$\lim_{n\to\infty} V\left[\widehat{\beta_{MCO}}\right] = 0$$

O también:

$$\operatorname*{plim}_{n\to\infty} \widehat{\beta_{MCO}} = \beta$$

- Teorema de Gauss – Markov: El estimador MCO es MELI (Mejor Estimador Lineal Insesgado). En otras palabras, no es posible encontrar otro estimador lineal e insesgado con menor varianza que el estimador MCO.

$$Varianza\ mínima\text{:}\ V\left[\widehat{\beta_{MCO}}\right] = \sigma^2 (X'X)^{-1}$$

Método de Máxima Verosimilitud (MV)

El método MV, a diferencia del método MCO, requiere de un supuesto respecto a la distribución de la variable de interés.

El método MV determina los estimadores que maximizan la probabilidad de ocurrencia de una muestra observada. La probabilidad de ocurrencia está representada en una función de distribución conjunta llamada "Función de Verosimilitud".

Sea $F(X_i = x_i) = F(x_i)$ la función de probabilidad acumulada de X_i evaluada en x_i, la Función de Verosimilitud $(L(\vartheta))$ corresponderá a la siguiente expresión:

$$L(\theta) = \mathrm{L}(x_1, x_2, \dots, x_n; \theta) = F_\theta(x_1, x_2, \dots, x_n)$$

Asumiendo que las observaciones X_i sin i.i.d. (idénticas e independientemente distribuidas):

$$F_\theta(x_1, x_2, \dots, x_n) = F(x_1; \theta) \times F(x_2; \theta) \times \cdots \times F(x_n; \theta) = \prod_{i=1}^{n} F(x_i; \theta)$$

Donde θ es vector de parámetros.

Método de Máxima Verosimilitud (MV) (2)

(Continuación)

Así, el objetivo del método MV será hallar el vector de parámetros θ que maximice la función de verosimilitud:

$$\widehat{\theta_{MV}} = max_{\theta}\ \mathrm{L}(x_1, x_2, \dots, x_n; \theta) = max_{\theta}\mathrm{Ln}\big(\mathrm{L}(x_1, x_2, \dots, x_n; \theta)\big)$$

Asimismo, podemos definir el logaritmo de la función de verosimilitud (*l(ϑ)*) como:

$$\mathrm{l}(x_1, x_2, \dots, x_n; \theta) = \mathrm{Ln}\big(\mathrm{L}(x_1, x_2, \dots, x_n; \theta)\big) = \sum_{i=1}^{n} Ln(F(x_i; \theta)$$

Para hallar los estimadores, se deberá igualar la primera derivada de la función de log – verosimilitud respecto al vector de parámetros θ a cero y resolver el sistema de ecuaciones que se presenta.

La primera derivada de la Función de Logverosimilitud es conocida como “Score”. Por tanto, el objetivo del método MV se conseguirá igualando el Score a cero.

Ejemplo de Método de Máxima Verosimilitud (MV)

A modo de ejemplo, para el caso de un modelo lineal, donde se asume que los errores siguen una distribución normal, los estimadores serán hallados al igualar el vector de primeras derivadas de *l(ϑ)* a cero:

$$\widehat{\beta_{MV}} = \frac{\sum_{i=1}^{n} y_i x_i}{\sum_{i=1}^{n} {x_i}^2}$$

$$\widehat{{\sigma^2}_{MV}} = \frac{1}{n}\sum_{i=1}^{n} {e_i}^2$$

O, en sus formas matriciales:

$$\widehat{\beta_{MV}} = (X'X)^{-1}(X'Y)$$

$$\widehat{{\sigma^2}_{MV}} = \frac{e'e}{n}$$

Ejemplo de Método de Máxima Verosimilitud (MV)

(Continuación)

Tomando la segunda propiedad del estimador MCO, la cual indica que el estimador MCO es el "Mejor Estimador Lineal Insesgado", podemos llegar a las siguientes conclusiones:

1. El estimador de beta por MV, al ser el mismo que el obtenido mediante MCO, es insesgado.
2. El estimador de la varianza de los errores por MV, al ser distintos al obtenido mediante MCO, es sesgado, además de menor en promedio que el parámetro teórico, dado que su sesgo es igual a:

$$-\frac{2}{n}\sigma^2$$

   Donde σ^2 es el parámetro teórico.

Los puntos mencionados anteriormente ratifican la principal ventaja del estimador MV: Es el mejor estimador cuando el estimador MCO falla.

Propiedades del Estimador MV

- Invarianza: Si $\widehat{\beta_{MV}}$ es el estimador MV de β y h(β) es una función continua de β, entonces, g($\widehat{\beta_{MV}}$) es el estimador MV de h(β).
- Consistencia: En muestras grandes, el estimador MV converge al parámetro poblacional:

$$\operatorname*{plim}_{n\to\infty} \widehat{\beta_{MV}} = \beta$$

  Esta propiedad también es conocida como "Insesgadez Asintótica".
- Normalidad Asintótica: En muestras grandes, el estimador MV sigue una distribución normal con el parámetro poblacional como media y el inverso de la matriz de información como varianza:

$$\widehat{\theta_{MV}} \to N(\theta, [I(\theta)]^{-1})$$

- Eficiencia Asintótica: La varianza del estimador MV alcanza la Cota de Cramer – Rao, la cual corresponde a la mínima varianza que puede poseer un estimador insesgado. Debido a la segunda propiedad, el estimador MV presenta eficiencia en grandes muestras.

Inferencia en el Contexto MV – Test LR

- Test de Ratio de Verosimilitud (LR): Se basa en el comparativo de funciones de verosimilitud de los parámetros estimados de los modelos irrestricto y restricto. Al respecto, si tenemos la hipótesis nula en forma matricial:

$$H_0\colon\ R\theta = r$$

Donde *R* es un vector de coeficientes de orden (*q x k*), donde *q* es el número de restricciones de la hipótesis nula y *k* es el número de parámetros estimados En ese sentido, *r* será un vector que contiene las restricciones y de orden (*q x 1*).

Luego, definimos el ratio de verosimilitud (*λ*) como:

$$\lambda = \frac{L(\widehat{\theta^*})}{L(\hat{\theta})}$$

Donde $L(\widehat{\theta^*})$ es el valor de la función de verosimilitud del modelo restricto. A partir de este ratio definimos el estadístico del test (LR):

$$LR = -2Ln\lambda = 2\left[LnL(\hat{\theta}) - LnL(\widehat{\theta^*})\right] \sim X_q^2$$

Donde *q* es el número de restricciones. Esto se cumple para todos los test en el contexto MV,

Inferencia en el Contexto MV – Test de Wald y LM

- Test de Wald (W): Elabora un estadístico basado en la diferencia entre el estimador y valor del parámetro asumido por la hipótesis nula. Al respecto, manteniendo la hipótesis nula:

$$H_0\colon\ R\theta = r$$

El estadístico de Wald (W) será el siguiente:

$$W = \left(R\hat{\theta} - r\right)'\left[RI\left(\hat{\theta}\right)^{-1}R'\right]^{-1}\left(R\hat{\theta} - r\right) \sim X_q^2$$

Así como en el caso anterior, el estadístico de Wald también sigue una distribución Chi cuadrado con el número de restricciones como grados de libertad.

- Test del Multiplicador de Lagrange (LM): También conocido como "Test del Score". En este caso, se comparará el Score del modelo irrestricto versus el Score del modelo restricto. Teóricamente, el Score se distribuye de la siguiente manera:

$$S(\theta) \rightarrow N(0, I(\theta))$$

Por lo tanto, el estadístico LM será:

$$LM = S(\widehat{\theta^*})'I(\widehat{\theta^*})^{-1}S(\widehat{\theta^*}) \sim X_q^2$$

El score asumido para el score del modelo irrestricto será cero por definición.

Método Generalizado de Momentos (MGM)

Este método se basa en el uso de las condiciones de momentos. Su notación usual es:

$$E[m(Y_i;\theta] = 0$$

Donde $m(Y_i;\vartheta)$ es una función (o vector de funciones) que depende de la forma funcional del modelo.

Por ejemplo, si se trata de un modelo lineal, las condiciones de momentos serán:

$$E[e_i] = 0$$

$$E[x_i e_i] = E\big[x_i E[e_i/x_i]\big] = 0$$

Este método puede presentar sobre identificación (número de condiciones es mayor al número de parámetros a estimar), lo cual afecta negativamente la eficiencia del estimador.

Test de Sobreidentificación en contexto MGM

El MGM presenta un Test de Sobre Identificación, donde la hipótesis nula será al siguiente:

$$H_0: E[m(Y_i;\theta] = 0$$

Y el estadístico será el siguiente:

$$J = n \times q(\hat{\theta}) \sim X^2_{k-p}$$

Donde:

$$q(\hat{\theta}) = \overline{m(\theta)}' \times V^{-1}\overline{m(\theta)}$$
$$\overline{m(\theta)} = E[\theta] - \hat{\theta}$$

Y V^{-1} es la inversa de la varianza de los estimadores de ϑ obtenidos de diferentes condiciones de momentos. Asimismo, *k* es el número de condiciones y *p* el de parámetros.

Por tanto, el test trabajará solo en caso de sobre identificación.

Método Mínimos Cuadrados en Dos Etapas (MC2E)

Es un método menos estudiado que los anteriores, pero será importante en tópicos próximos. Al respecto, la estimación se llevará a cabo en dos etapas, las cuales corresponden a:

- Etapa 1: Se estima un modelo donde la variable dependiente será aquella de la cual solo se requieren sus valores predichos.
- Etapa 2: Se sustituyen las observaciones de las variables dependientes de la Etapa 1 por sus valores predichos en el modelo original antes de realizar la estimación.

Los estimadores son consistentes pero pueden ser sesgados.